Analise_ML

February 19, 2021

[1]:
```
import pandas as pd
import numpy as np

pd.set_option('display.max_rows', None)
```

1 Questão 1

1.1 O Conjunto de Dados

Inicialmente será realizado o preenchimento dos dados ausentes da coluna "True_class" com os dados da coluna "Pred_class".

[2]:
```
df = pd.read_excel('../data/teste_smarkio_lbs.xls')
```

[3]:
```
df.head()
```

[3]:

	Pred_class	probabilidade	status	True_class
0	2	0.079892	approved	0.0
1	2	0.379377	approved	74.0
2	2	0.379377	approved	74.0
3	2	0.420930	approved	74.0
4	2	0.607437	approved	NaN

[4]:
```
df.True_class.fillna(df.Pred_class, inplace=True)

df.head()
```

[4]:

	Pred_class	probabilidade	status	True_class
0	2	0.079892	approved	0.0
1	2	0.379377	approved	74.0
2	2	0.379377	approved	74.0
3	2	0.420930	approved	74.0
4	2	0.607437	approved	2.0

Com os dados ajustados, foi realizada uma análise do conjunto de dados como um todo, levantando suas principais informações, como quantidade de linhas e colunas e tipo de dados por coluna.

[5]:
```
print("Dimensões do dataframe: ")
print("Linhas: ", df.shape[0])
print("Colunas: ", df.shape[1])
```

```
Dimensões do dataframe:
Linhas:  643
Colunas:  4
```

[6]:
```
pd.concat([pd.DataFrame([[cols, str(df[cols].dtype)]], columns=['Colunas', 'Tipo␣
 ↪de Informação']) for cols in df.columns], ignore_index=True)
```

[6]:

	Colunas	Tipo de Informação
0	Pred_class	int64
1	probabilidade	float64
2	status	object
3	True_class	float64

1.2 Análises com 1 variável

1.2.1 Variável: Pred_class

Em seguida, foi realizada uma análise das colunas individualmente.

A primeira coluna analisada será a coluna "Pred_class". Os dados desta coluna são dados qualitativos, ou seja, dados que representam uma característica do objeto observado, nesse caso em específico os dados indicam a classe que foi identificada pelo modelo.

Para esses dados, foi levantado a quantidade de classes identificadas pelo modelo e quais foram essas clases.

[7]:
```
print('Quantidade de classes: ', df.Pred_class.nunique())

print('\n')

print('Classes Identificadas: ', df.Pred_class.unique())
```

```
Quantidade de classes:  80


Classes Identificadas:  [  2   3   4  11  17  22  24  26  32  33  48  50  52  55
60  62  64  74
  77  82  85  87  92  93  96  98  99 102 103 104 106 107 108 109 110 116
 118  25  28  29  40  49  68 111  19  30  39  58  65  81  31  43  69  90
  12  15  21  54  59  63  70  76  78  79  86  88 112 115  46  56  73  94
  95 100 105  66 114 113  36  84]
```

O próximo passo foi elaborar uma Tabela de Frequência com os dados dessa coluna.

[8]:
```
n = df.shape[0]

pd.concat([pd.DataFrame([[classe, (df.Pred_class == classe).sum(), ((df.
 ↪Pred_class == classe).sum() / n) * 100]], columns=['Classe', 'Frequência␣
 ↪Absoluta', 'Frequência Relativa (%)']) for classe in df.Pred_class.unique()],␣
 ↪ignore_index=True).sort_values('Frequência Absoluta', ascending=False,␣
 ↪ignore_index=True)
```

[8]:

	Classe	Frequência Absoluta	Frequência Relativa (%)
0	3	63	9.797823
1	2	61	9.486781
2	74	59	9.175739
3	77	31	4.821151
4	60	31	4.821151
5	4	23	3.576983
6	96	21	3.265941
7	52	20	3.110420
8	55	17	2.643857
9	110	16	2.488336
10	22	15	2.332815
11	99	14	2.177294
12	85	14	2.177294
13	24	14	2.177294
14	108	13	2.021773
15	25	12	1.866252
16	103	9	1.399689
17	11	9	1.399689
18	32	8	1.244168
19	76	8	1.244168
20	29	7	1.088647
21	40	7	1.088647
22	17	7	1.088647
23	43	6	0.933126
24	12	6	0.933126
25	39	6	0.933126
26	118	5	0.777605
27	115	5	0.777605
28	81	5	0.777605
29	30	5	0.777605
30	19	5	0.777605
31	92	5	0.777605
32	82	5	0.777605
33	102	5	0.777605
34	98	5	0.777605
35	62	4	0.622084
36	104	4	0.622084
37	59	4	0.622084

38	106	4	0.622084
39	109	4	0.622084
40	87	4	0.622084
41	112	4	0.622084
42	26	3	0.466563
43	15	3	0.466563
44	56	3	0.466563
45	90	3	0.466563
46	70	3	0.466563
47	33	3	0.466563
48	88	3	0.466563
49	78	3	0.466563
50	86	3	0.466563
51	111	3	0.466563
52	68	3	0.466563
53	79	3	0.466563
54	65	3	0.466563
55	63	2	0.311042
56	54	2	0.311042
57	73	2	0.311042
58	31	2	0.311042
59	49	2	0.311042
60	28	2	0.311042
61	48	2	0.311042
62	116	2	0.311042
63	50	2	0.311042
64	105	1	0.155521
65	95	1	0.155521
66	114	1	0.155521
67	113	1	0.155521
68	36	1	0.155521
69	100	1	0.155521
70	66	1	0.155521
71	21	1	0.155521
72	94	1	0.155521
73	46	1	0.155521
74	69	1	0.155521
75	93	1	0.155521
76	58	1	0.155521
77	64	1	0.155521
78	107	1	0.155521
79	84	1	0.155521

Podemos notar uma alta ocorrência das classes 3, 2 e 74 em relação as outras.

Em seguida, foi levantado algumas características estatísticas da "Frequência Absoluta", como média, desvio padrão, minimo, quartis 25%, 50% (mediana) e 75%, e máximo.

[9]:
```
pd.concat([pd.DataFrame([[classe, (df.Pred_class == classe).sum(), ((df.
↪Pred_class == classe).sum() / n) * 100]], columns=['Classe', 'Frequência␣
↪Absoluta', 'Frequência Relativa (%)']) for classe in df.Pred_class.unique()],␣
↪ignore_index=True).sort_values('Frequência Absoluta', ascending=False,␣
↪ignore_index=True).describe().drop(['Classe', 'Frequência Relativa (%)'], axis␣
↪= 1)
```

[9]:

	Frequência Absoluta
count	80.00000
mean	8.03750
std	12.33339
min	1.00000
25%	2.00000
50%	4.00000
75%	7.25000
max	63.00000

É interessante notar a diferença da média (aproximadamente 8) pra mediana (4). Isso indica que a distribuição dos dados está deslocada para a direita, isto é, algumas poucas classes contém a maior quantidade de ocorrências.

1.2.2 Variável: probabilidade

Diferente do caso anterior, a coluna "probabilidade" apresenta dados quantitativos, isto é, dados que possuem significado numérico.

Para esses dados, foi levantado as suas características estatísticas, como média, desvio padrão, minimo, quartis 25%, 50% (mediana) e 75%, e máximo.

[10]:
```
df.drop(['Pred_class', 'True_class'], axis = 1).describe()
```

[10]:

	probabilidade
count	643.000000
mean	0.622436
std	0.266811
min	0.043858
25%	0.408017
50%	0.616809
75%	0.870083
max	1.000000

No gráfico abaixo, é apresentado um diagrama de caixa da distribuição desses dados.

O quadrado central do diagrama é formado pelos quartis 25% e 75%. A linha verde ao centro indica a mediana (quartil 50%) dos dados. E as linhas pretas fora da caixa indicam os valores máximo e mínimo dos dados.

[11]:
```
df.drop(['Pred_class', 'True_class'], axis = 1).boxplot()
```

[11]: <matplotlib.axes._subplots.AxesSubplot at 0x16ababb2208>

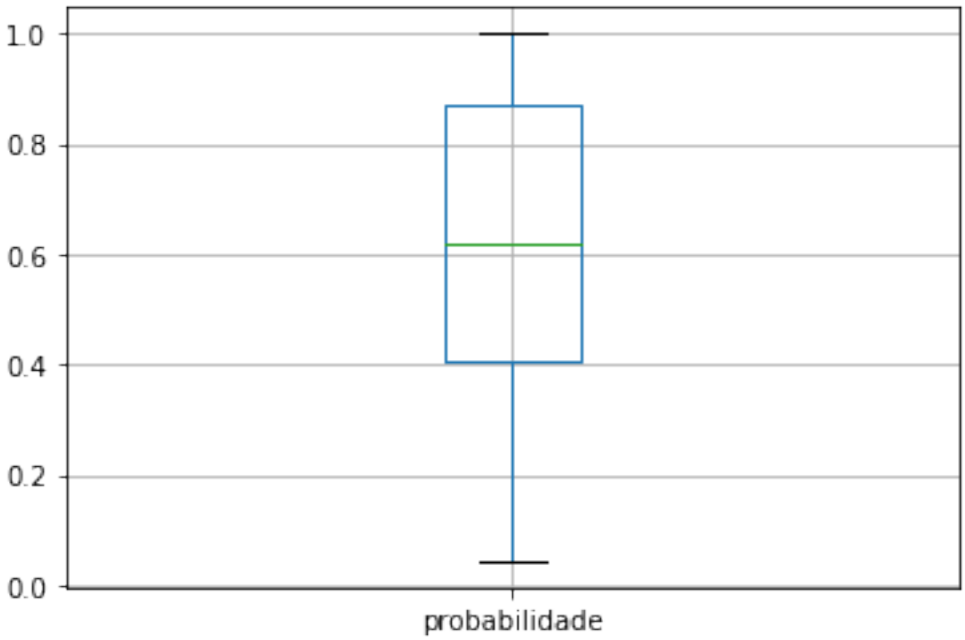

Com a média e a mediana, podemos perceber uma simetria nas probabilidades em aproximadamente 62%. Outra informação relevante que podemos tirar dessas características, ao analisar o quartil 25%, é que para 75% das amostras o modelo possuia pelo menos 40% de probabilidade. E para 25% das amostras o modelo indicou quase 90% de probabilidade, indicado pelo quartil 75%.

Além disso, essa variável possibilitará calcular nas próximas etapas a entropia cruzada do modelo.

1.2.3 Variável: status

Individualmente, a variável status é uma variável com menos informação.

Ela indica o status da classificação da predição do modelo de acordo com um especialista e apresenta apenas 2 classes: approved e revision. Com 600 amostras aprovadas e 43 para revisão.

[12]:
```
print('Quantidade de classes: ', df.status.nunique())

print('\n')

print('Classes Identificadas: ', df.status.unique())

print('\n')

print('Amostras aprovadas: ', df.status.value_counts().iloc[0])

print('\n')
```

```
print('Amostras para revisão: ', df.status.value_counts().iloc[1])
```

```
Quantidade de classes:  2


Classes Identificadas:  ['approved' 'revision']


Amostras aprovadas:  600


Amostras para revisão:  43
```

1.2.4 Variável: True_class

Para a coluna "True_class", foi extraído as mesmas informações da coluna "Pred_class".

[13]:
```
print('Quantidade de classes: ', df.True_class.nunique())

print('\n')

print('Classes Identificadas: ', df.True_class.unique())
```

```
Quantidade de classes:  73


Classes Identificadas:  [  0.  74.   2.   3. 108.  79.  24.  98.   4.  11.  17.
85.  22.  48.
  52.  73.  55.  60.  62.  77.  82.  87.  93.  96.  99. 102. 103. 104.
 106. 107. 110. 116.  81. 118.  32.  25.  29.  40.  19. 111.  15.  58.
  65.  66.  12.  28.  43.  68.  69.  92.  76.  26.  30.  54.  59.  86.
  63.  70.  78. 117.  88. 112. 115.  39.  46.  56.  90.  94. 100. 114.
 113.  36.  84.]
```

[14]:
```
n = df.shape[0]

pd.concat([pd.DataFrame([[classe, (df.True_class == classe).sum(), ((df.
 ↪True_class == classe).sum() / n) * 100]], columns=['Classe', 'Frequência␣
 ↪Absoluta', 'Frequência Relativa (%)']) for classe in df.True_class.unique()],␣
 ↪ignore_index=True).sort_values('Frequência Absoluta', ascending=False,␣
 ↪ignore_index=True)
```

[14]:

	Classe	Frequência Absoluta	Frequência Relativa (%)
0	74.0	78	12.130638
1	2.0	61	9.486781
2	3.0	60	9.331260
3	0.0	54	8.398134

4	77.0	29	4.510109
5	60.0	28	4.354588
6	4.0	21	3.265941
7	96.0	21	3.265941
8	24.0	16	2.488336
9	55.0	15	2.332815
10	110.0	11	1.710731
11	22.0	11	1.710731
12	25.0	10	1.555210
13	85.0	10	1.555210
14	76.0	10	1.555210
15	108.0	10	1.555210
16	99.0	10	1.555210
17	81.0	9	1.399689
18	40.0	9	1.399689
19	17.0	8	1.244168
20	102.0	8	1.244168
21	12.0	7	1.088647
22	29.0	7	1.088647
23	79.0	7	1.088647
24	98.0	7	1.088647
25	87.0	6	0.933126
26	52.0	6	0.933126
27	103.0	6	0.933126
28	62.0	5	0.777605
29	19.0	5	0.777605
30	82.0	5	0.777605
31	86.0	5	0.777605
32	115.0	5	0.777605
33	32.0	4	0.622084
34	48.0	4	0.622084
35	11.0	4	0.622084
36	70.0	4	0.622084
37	39.0	4	0.622084
38	30.0	3	0.466563
39	78.0	3	0.466563
40	56.0	3	0.466563
41	43.0	3	0.466563
42	15.0	3	0.466563
43	117.0	3	0.466563
44	116.0	3	0.466563
45	88.0	3	0.466563
46	112.0	3	0.466563
47	65.0	2	0.311042
48	58.0	2	0.311042
49	90.0	2	0.311042
50	68.0	2	0.311042

51	118.0	2	0.311042
52	92.0	2	0.311042
53	73.0	2	0.311042
54	26.0	2	0.311042
55	54.0	2	0.311042
56	63.0	2	0.311042
57	93.0	1	0.155521
58	46.0	1	0.155521
59	100.0	1	0.155521
60	114.0	1	0.155521
61	113.0	1	0.155521
62	36.0	1	0.155521
63	94.0	1	0.155521
64	69.0	1	0.155521
65	59.0	1	0.155521
66	28.0	1	0.155521
67	66.0	1	0.155521
68	111.0	1	0.155521
69	107.0	1	0.155521
70	106.0	1	0.155521
71	104.0	1	0.155521
72	84.0	1	0.155521

[15]:
```
pd.concat([pd.DataFrame([[classe, (df.True_class == classe).sum(), ((df.
↪True_class == classe).sum() / n) * 100]], columns=['Classe', 'Frequência␣
↪Absoluta', 'Frequência Relativa (%)']) for classe in df.True_class.unique()],␣
↪ignore_index=True).sort_values('Frequência Absoluta', ascending=False,␣
↪ignore_index=True).describe().drop(['Classe', 'Frequência Relativa (%)'], axis␣
↪= 1)
```

[15]:

	Frequência Absoluta
count	73.000000
mean	8.808219
std	14.588482
min	1.000000
25%	2.000000
50%	4.000000
75%	9.000000
max	78.000000

1.3 Análise com 2 variáveis

1.3.1 Variáveis: Pred_class e True_class

Ao comparar as informações já extraidas da coluna "Pred_class" com a coluna "True_class" é possível notar algumas coisas.

A primeira delas é a quantidade de classes existentes em cada coluna. Enquanto na coluna

"Pred_class" existem 80 classes, na coluna "True_class" aparecem apenas 73 classes. **Isto é um forte indicio que nos dados de treinamento existiam dados com mais classes que nos dados de teste.**

Outra informação em destaque é a presença da classe 74. Na coluna "Pred_class" ela era a terceira classe com mais ocorrência, com 59 ocorrências. Já na coluna "True_class" a classe 74 possui 78 ocorrências e é a classe com mais ocorrência.

Além disso, a classe 0 aparece como quarta classe com mais ocorrência na coluna "True_class", com 54 ocorrências. Por outro lado, na coluna "Pred_class" ela não aparece. **Isto pode indicar que no treinamento do modelo haviam poucos ou nenhum registro pertencente a classe 0, o que levou o modelo a não indicar essa classe.**

Com essas variáveis, podemos levantar e analisar os casos em que o modelo errou.

[16]:
```
df_erros = df.query('Pred_class != True_class')
```

[17]:
```
df_erros.True_class.value_counts().head()
```

[17]:
```
0.0     54
74.0    22
2.0     14
3.0     10
24.0     6
Name: True_class, dtype: int64
```

O erros do modelo foram em sua maioria na classe 0, seguido das classes 72 e 2. Como comentado anteriormente, isto pode indicar que o modelo possuia poucos exemplos com essas classes no treinamento.

[18]:
```
df_erros.Pred_class.value_counts().head()
```

[18]:
```
2     14
52    14
3     13
85     8
77     7
Name: Pred_class, dtype: int64
```

Por outro lado, as maiores quantidade de erros nas previsões foram nas classes 2, 52 e 3. Isto pode indicar que o treinamento foi realizado com uma maior quantidade de exemplos nessas classes.

Aprofundando um pouco mais nos erros do modelo, foi levantado um tabela para as classes com mais erros na previsão indicando quais eram as classes corretas e a quantidade de vezes que ocorreu esse erro.

[19]:
```
classes_com_mais_erros = [2, 52, 3]
```

```
pd.concat([pd.DataFrame([[classe, unicos, (df_erros[df_erros.Pred_class ==␣
↪classe].True_class == unicos).sum()]], columns=['Pred_class', 'True_class',␣
↪'Quantidade de erros']) for classe in classes_com_mais_erros for unicos in␣
↪df_erros[df_erros.Pred_class == classe].True_class.unique()],␣
↪ignore_index=True).sort_values(['Pred_class', 'Quantidade de erros'],␣
↪ascending=[True, False], ignore_index=True)
```

[19]:

	Pred_class	True_class	Quantidade de erros
0	2	74.0	7
1	2	0.0	2
2	2	55.0	1
3	2	3.0	1
4	2	40.0	1
5	2	96.0	1
6	2	79.0	1
7	3	24.0	2
8	3	0.0	2
9	3	108.0	1
10	3	79.0	1
11	3	32.0	1
12	3	15.0	1
13	3	66.0	1
14	3	40.0	1
15	3	19.0	1
16	3	85.0	1
17	3	74.0	1
18	52	0.0	14

Nessa tabela podemos notar 2 tendência de erros: o modelo indicar classe 2 quando a classe verdadeira é 74 e, principalmente, o modelo indicar classe 52 quando a classe verdadeira é 0.

1.3.2 Variáveis: probabilidade e status

Uma outra análise que podemos fazer é buscar identificar se existe alguma relação entre as colunas "probabilidade" e "status", ou seja, buscar identificar se as amostras que o especilista marcou como "approved" possuem maior probabilidade que as amostras marcadas como "revision".

[20]:
```
df[df.status == 'approved'].describe().drop(['Pred_class','True_class'], axis =␣
↪1)
```

[20]:

	probabilidade
count	600.000000
mean	0.629549
std	0.270583
min	0.043858
25%	0.411801
50%	0.635104
75%	0.881497

```
max         1.000000
```

[21]:
```
df[df.status == 'revision'].describe().drop(['Pred_class','True_class'], axis =
↪1)
```

[21]:
```
       probabilidade
count      43.000000
mean        0.523184
std         0.182102
min         0.278516
25%         0.345885
50%         0.511118
75%         0.654347
max         0.909148
```

As informações das colunas anteriores nos mostram que provavelmente existe uma relação entre as colunas "probabilidade" e "status". Para verificar isto iremos realizar o teste t. Começemos definindo a hipótese nula H0.

```
H0 = A média da probabilidade para o conjunto que o especialista marcou como approved é igual a
```

Alternativamente, temos:

```
H1 = As médias das probabilidades são diferentes
```

E assumindo um nível de significância alpha de 0.05, isto é, uma taxa tolerável do erro de 5%, temos:

[22]:
```
from scipy import stats

stats.ttest_ind(df[df.status == 'approved'].probabilidade, df[df.status ==
↪'revision'].probabilidade)
```

[22]:
```
Ttest_indResult(statistic=2.5358689388146742, pvalue=0.01145322772678419)
```

Como o p_valor é menor que 5%, podemos rejeitar a hipótese nula de que as médias são iguais. Logo, com o resultado do teste, podemos confimar que os exemplos marcados como "approved" pelo especialista apresentaram maior média de probabilidade do que os marcados como "revision".

1.4 Análise com 3 variáveis

1.4.1 Variáveis: Pred_class, probabilidade e True_class

Outra informação que podemos buscar no modelo é a distribuição da probabilidade para os casos em que o modelo errou. Com isso, o esperado seja que o modelo tenha errado casos com probabilidade baixa. Ou seja, o modelo errou em casos que ele não tinha muita certeza da classe

[23]:
```
df_acertos = df.query('Pred_class == True_class')
```

[24]:
```
df_acertos.describe().drop(['Pred_class', 'True_class'], axis = 1)
```

[24]:

	probabilidade
count	462.000000
mean	0.695781
std	0.241508
min	0.056703
25%	0.442174
50%	0.740184
75%	0.921272
max	1.000000

[25]:
```
df_erros.describe().drop(['Pred_class', 'True_class'], axis = 1)
```

[25]:

	probabilidade
count	181.000000
mean	0.435223
std	0.235527
min	0.043858
25%	0.296034
50%	0.402339
75%	0.611993
max	0.969570

Podemos realizar para este caso outro teste t, com:

```
H0 = A média da probabilidade para o conjunto de acertos do modelo é igual a média para o conjun
errou.
```

Alternativamente, temos:

```
H1 = As médias das probabilidas são diferentes
```

[26]:
```
rejeitar = pd.Series(dtype='float64')

stats.ttest_ind(df_acertos.sample(60).probabilidade, df_erros.sample(60).
 ↪probabilidade)
```

[26]:
```
Ttest_indResult(statistic=4.668344904970055, pvalue=8.094436450125209e-06)
```

Como o p_valor foi muito menor que 5%, podemos rejeitar a hipótese nula de que as médias são iguais.

Com isso, podemos concluir então que a maior parte dos erros do modelo foi em casos que a probabilidade era baixa.

2 Questão 2

3 Avaliação do Modelo

[27]:
```
from sklearn.metrics import classification_report
```

A avaliação do modelo será realizada utilizando as seguintes métricas:

3.1 Acurácia

A acurácia nos diz quantos de nossos exemplos foram de fato classificados corretamente, independente da classe. Por exemplo, se temos 100 observações e 90 delas foram classificados corretamente, nosso modelo possui uma acurácia de 90%. A acurácia é definida pela fórmula abaixo:

```
Acurácia = Quantidade de Acertos / (Quantidade de Acertos + Quantidade de Erros)
```

3.2 Precisão

A precisão também é uma das métricas mais comuns para avaliar modelos de classificação. Esta métrica é definida pela razão entre a quantidade de exemplos classificados corretamente como positivos e o total de exemplos classificados como positivos, conforme a fórmula abaixo:

```
Precisão = Acertos positivos / (Acertos positivos + Erros positivos)
```

3.3 Recall

Ao contrário da precisão, o recall dá maior ênfase para os erros por falso negativo. Esta métrica é definida pela razão entre a quantidade de exemplos classificados corretamente como positivos e a quantidade de exemplos que são de fato positivos, conforme a fórmula abaixo:

```
Recall = Acertos positivos / (Acertos positivos + Erros Negativos)
```

3.4 F1-score

O F1 score leva em consideração tanto a precisão quanto o recall. Ela é definida pela média harmônica entre as duas, como pode ser visto abaixo:

```
F1_score = 2 * (precisão * recall) / (precisão + recall)
```

Essas 4 primeiras métricas podem ser facilmente obtidas com a função classification_report do sklearn.

[28]:
```
print(classification_report(df.True_class, df.Pred_class))
```

```
              precision    recall  f1-score   support

         0.0       0.00      0.00      0.00        54
         2.0       0.77      0.77      0.77        61
         3.0       0.79      0.83      0.81        60
         4.0       0.78      0.86      0.82        21
        11.0       0.44      1.00      0.62         4
```

12.0	0.83	0.71	0.77	7
15.0	0.67	0.67	0.67	3
17.0	0.86	0.75	0.80	8
19.0	0.40	0.40	0.40	5
21.0	0.00	0.00	0.00	0
22.0	0.67	0.91	0.77	11
24.0	0.71	0.62	0.67	16
25.0	0.83	1.00	0.91	10
26.0	0.33	0.50	0.40	2
28.0	0.50	1.00	0.67	1
29.0	1.00	1.00	1.00	7
30.0	0.60	1.00	0.75	3
31.0	0.00	0.00	0.00	0
32.0	0.25	0.50	0.33	4
33.0	0.00	0.00	0.00	0
36.0	1.00	1.00	1.00	1
39.0	0.67	1.00	0.80	4
40.0	1.00	0.78	0.88	9
43.0	0.50	1.00	0.67	3
46.0	1.00	1.00	1.00	1
48.0	0.50	0.25	0.33	4
49.0	0.00	0.00	0.00	0
50.0	0.00	0.00	0.00	0
52.0	0.30	1.00	0.46	6
54.0	1.00	1.00	1.00	2
55.0	0.82	0.93	0.87	15
56.0	1.00	1.00	1.00	3
58.0	1.00	0.50	0.67	2
59.0	0.25	1.00	0.40	1
60.0	0.81	0.89	0.85	28
62.0	0.75	0.60	0.67	5
63.0	1.00	1.00	1.00	2
64.0	0.00	0.00	0.00	0
65.0	0.33	0.50	0.40	2
66.0	0.00	0.00	0.00	1
68.0	0.67	1.00	0.80	2
69.0	1.00	1.00	1.00	1
70.0	1.00	0.75	0.86	4
73.0	0.50	0.50	0.50	2
74.0	0.95	0.72	0.82	78
76.0	1.00	0.80	0.89	10
77.0	0.77	0.83	0.80	29
78.0	1.00	1.00	1.00	3
79.0	1.00	0.43	0.60	7
81.0	0.60	0.33	0.43	9
82.0	1.00	1.00	1.00	5
84.0	1.00	1.00	1.00	1
85.0	0.43	0.60	0.50	10

```
        86.0       0.33      0.20      0.25         5
        87.0       1.00      0.67      0.80         6
        88.0       1.00      1.00      1.00         3
        90.0       0.67      1.00      0.80         2
        92.0       0.20      0.50      0.29         2
        93.0       1.00      1.00      1.00         1
        94.0       1.00      1.00      1.00         1
        95.0       0.00      0.00      0.00         0
        96.0       0.90      0.90      0.90        21
        98.0       1.00      0.71      0.83         7
        99.0       0.57      0.80      0.67        10
       100.0       1.00      1.00      1.00         1
       102.0       1.00      0.62      0.77         8
       103.0       0.67      1.00      0.80         6
       104.0       0.25      1.00      0.40         1
       105.0       0.00      0.00      0.00         0
       106.0       0.25      1.00      0.40         1
       107.0       1.00      1.00      1.00         1
       108.0       0.69      0.90      0.78        10
       109.0       0.00      0.00      0.00         0
       110.0       0.69      1.00      0.81        11
       111.0       0.33      1.00      0.50         1
       112.0       0.50      0.67      0.57         3
       113.0       1.00      1.00      1.00         1
       114.0       1.00      1.00      1.00         1
       115.0       0.80      0.80      0.80         5
       116.0       1.00      0.67      0.80         3
       117.0       0.00      0.00      0.00         3
       118.0       0.40      1.00      0.57         2

    accuracy                           0.72       643
   macro avg       0.63      0.70      0.64       643
weighted avg       0.72      0.72      0.70       643


C:\Users\muril\anaconda3\lib\site-
packages\sklearn\metrics\_classification.py:1272: UndefinedMetricWarning:
Precision and F-score are ill-defined and being set to 0.0 in labels with no
predicted samples. Use `zero_division` parameter to control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))
C:\Users\muril\anaconda3\lib\site-
packages\sklearn\metrics\_classification.py:1272: UndefinedMetricWarning: Recall
and F-score are ill-defined and being set to 0.0 in labels with no true samples.
Use `zero_division` parameter to control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))
```

4 Questão 3

Para a questão 3, os dados foram separados em dois conjuntos. Um conjunto contém os dados que o especialista marcou como approved e será usado para o treinamento do classificador. No segundo conjunto ficou os dados marcados como revision onde será aplicado o classificador.

[29]:
```
dataset_approved = df[df.status == 'approved']
dataset_revision = df[df.status == 'revision']
```

[30]:
```
dataset_approved.head()
```

[30]:

	Pred_class	probabilidade	status	True_class
0	2	0.079892	approved	0.0
1	2	0.379377	approved	74.0
2	2	0.379377	approved	74.0
3	2	0.420930	approved	74.0
4	2	0.607437	approved	2.0

O próximo passo foi criar uma coluna 'y' que receberá 'True' se 'Pred_class' foi igual a 'True_class' e 'False' se forem diferentes. Essa coluna será usadacomo target do classificador.

[31]:
```
dataset_approved['y'] = dataset_approved.Pred_class == dataset_approved.
↪True_class
```

```
C:\Users\muril\anaconda3\lib\site-packages\ipykernel_launcher.py:1:
SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-
docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
  """Entry point for launching an IPython kernel.
```

[32]:
```
dataset_approved.head()
```

[32]:

	Pred_class	probabilidade	status	True_class	y
0	2	0.079892	approved	0.0	False
1	2	0.379377	approved	74.0	False
2	2	0.379377	approved	74.0	False
3	2	0.420930	approved	74.0	False
4	2	0.607437	approved	2.0	True

O classificador que será usado é uma Random Forest, por ser uma classificador simples e rápido.

O classificador foi avaliado usando é técnica de cross-validation.

[33]:
```
from sklearn.ensemble import RandomForestClassifier as rfc
from sklearn.model_selection import cross_val_score
```

```
clf = rfc()
scores = cross_val_score(clf, dataset_approved[['Pred_class', 'probabilidade']],␣
 ↪dataset_approved.y, cv=5)
scores
```

[33]:
```
array([0.725     , 0.71666667, 0.81666667, 0.75833333, 0.75833333])
```

[34]:
```
clf.fit(dataset_approved[['Pred_class', 'probabilidade']], dataset_approved.y)
```

[34]:
```
RandomForestClassifier(bootstrap=True, ccp_alpha=0.0, class_weight=None,
                       criterion='gini', max_depth=None, max_features='auto',
                       max_leaf_nodes=None, max_samples=None,
                       min_impurity_decrease=0.0, min_impurity_split=None,
                       min_samples_leaf=1, min_samples_split=2,
                       min_weight_fraction_leaf=0.0, n_estimators=100,
                       n_jobs=None, oob_score=False, random_state=None,
                       verbose=0, warm_start=False)
```

[35]:
```
clf.predict(dataset_revision[['Pred_class', 'probabilidade']])
```

[35]:
```
array([ True,  True,  True,  True,  True,  True, False,  True, False,
       False,  True,  True, False,  True,  True,  True,  True, False,
        True,  True,  True,  True,  True,  True,  True,  True,  True,
       False, False,  True,  True,  True, False, False,  True, False,
        True,  True,  True,  True,  True,  True,  True])
```

Assim como para os dados com status 'approved', foi criada uma coluna 'y' para so dados em 'revision'

[36]:
```
dataset_revision['y'] = dataset_revision.Pred_class == dataset_revision.
 ↪True_class
```

```
C:\Users\muril\anaconda3\lib\site-packages\ipykernel_launcher.py:1:
SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-
docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
  """Entry point for launching an IPython kernel.
```

Com isso, podemos avaliar o desempenho da random forest. Para isso, foi plotada a matriz de confusão e calculada as métricas precisão, recall e f1-score.

[37]:
```
from sklearn.metrics import plot_confusion_matrix

plot_confusion_matrix(clf, dataset_revision[['Pred_class', 'probabilidade']],␣
 ↪dataset_revision['y'])
```

[37]: <sklearn.metrics._plot.confusion_matrix.ConfusionMatrixDisplay at 0x16ad4c0d548>

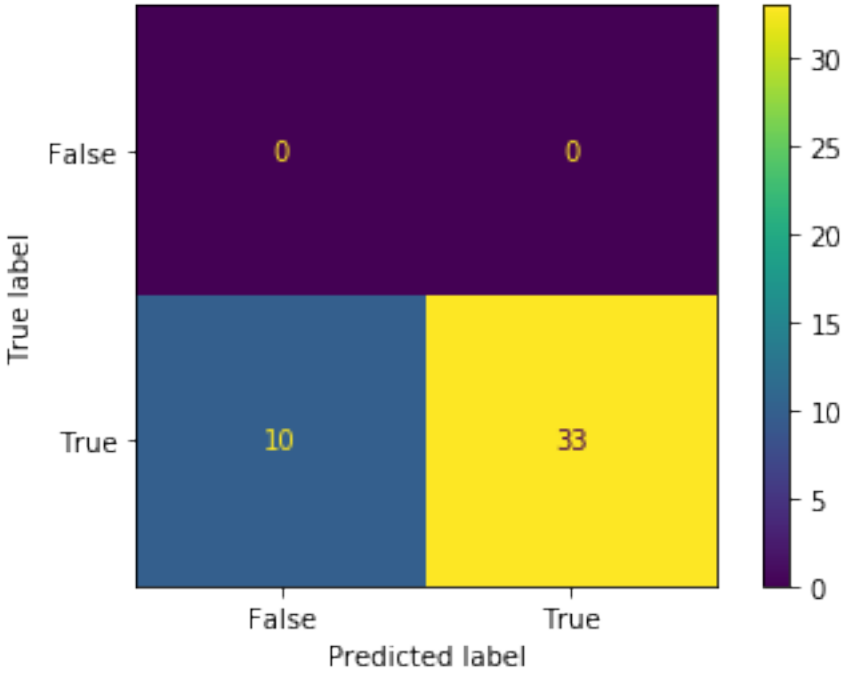

[38]:
```
print(classification_report(dataset_revision['y'], clf.
↪predict(dataset_revision[['Pred_class', 'probabilidade']])))
```

```
              precision    recall  f1-score   support

       False       0.00      0.00      0.00         0
        True       1.00      0.77      0.87        43

    accuracy                           0.77        43
   macro avg       0.50      0.38      0.43        43
weighted avg       1.00      0.77      0.87        43
```

```
C:\Users\muril\anaconda3\lib\site-
packages\sklearn\metrics\_classification.py:1272: UndefinedMetricWarning: Recall
and F-score are ill-defined and being set to 0.0 in labels with no true samples.
Use `zero_division` parameter to control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))
```

Como apresentado anteriormente, a métrica precision é tendenciada e dar maior relevância para erros do tipo Falso Positivo. E, como os dados com status 'revision' não apresentaram nenhum exemplo em que Pred_class estivesse errada, este tipo de erro não ocorreu. Com isso, a precisão de acertos do modelo foi de 100%.

Por outro lado, a métrica recall, que considera erros do tipo Falso Negativo, levou em consideração

os 10 erros cometido pelo modelo e ficou em 77%.

Por fim, como o F1 score leva em consideração tanto a precisão quanto o recall, ficou em 87%. Um "meio-termo" entre as outras duas métricas.